Search Engine 实验报告

学号-2014211280-谢非 2016年12月28日

目录

5	实验总结	4
	4.2 实现查找	3
	4.1 创建索引	
4	实验原理	3
3	实验环境	2
2	实验要求	2
1	实验目的	2

1 实验目的 2

1 实验目的

1. 应用信息提取的基本原理来实现一个简单的搜索引擎

2 实验要求

- 1. 实现一个信息提取系统(搜索引擎)
- 2. 实现引擎的模糊搜索和全文检索功能

3 实验环境

实验代码使用 python3.5 实现. 测试数据是 http://www.cs.cmu.edu/afs/cs/project/theo-11/www/naive-bayes.html这个网站上的 20 个新闻组资料, 即之前文本分类的 20 个新闻组资源. 不过实际试运行时只选取了测试数据中的 100 个文本数据.

4 实验原理 3

4 实验原理

4.1 创建索引

首先将所有文本数据去除标点符号以及停用词 ¹剔除,之后将每个文本转化为一个单词列表. 然后,记录每个单词出现的索引位置. 实现时采用字典存储,单词是键,值是其出现的索引位置的列表. 在处理 完所有的单个文件之后,再次扫描所有的索引 ²,建立全局的倒排索引表,键是单词,值是一个字典(该字典内,键是文件名,值是该单词在文件中的索引列表).

4.2 实现查找

具体查找时需要对输入的字符串进行分词,对所有的单词,在全局索引表中获取该单词对应的文件和文件内位置. 之后根据文件内总体的关键字出现次数,来计算出该文件的权重,由权重对文件进行重排. 重排后根据第一个索引的位置构造出该单词在文件中出现的大体位置(相邻的字符串)返回结果. 运行样例如下,

```
indexData.getStopWords("stopWords.txt")
allIndexs = indexData.createIndex()
allIndexs.loadAllFiles(["./data/"])
queryTool=query.QueryStr(allIndexs.allIndex,allIndexs.allDocs)
queryTool.query("i am good")
```

返回结果如下(包括该文件以及关键词出现的位置):

```
X件A文件內美維學而華麗的如下:
//data/38978 ... a truly lossless compression algorithm i e one that guarantees....avoided or limited but I am not optimistic about it....compress images 5 M/data/38953 ... model2.4 460 vertices 206 useful i e referred to in....hal physics wayne edu I am writing my own visualization.....24 bit scanning Get a good 24 //data/38375 . some stuff for scientific graphs i e log axes free....tool and it is very good for this purpose Dimple...
//data/38379 . familiar with graphics and I am not expecting for any....know if there are any good 2d graphics packages available...
//data/38930 . lines just a hair backwards i e smaller VRC 2.
//data/38951 . lines just a hair backwards i e smaller VRC 2.
//data/38951 . lines just a hair backwards i e smaller VRC 2.
//data/38951 . lines just a hair backwards i e smaller VRC 2.
//data/38951 . lines just a hair backwards i e smaller VRC 2.
//data/389531 . lines just a hair backwards i e smaller VRC 2.
//data/389531 . lines just a hair backwards i e smaller VRC 2.
//data/389531 . lines just a hair backwards i e smaller VRC 2.
//data/389531 . lines is 15 Hi there Well i have a 386 40
//data/38950 ... sum ac za writes I am also looking for a.... chessboard Right here is as good a place as any...
//data/38950 ... sum ac za writes I am also looking for a... chessboard Right here is as good a place as any...
//data/38950 ... sum ac za writes I am also looking for a... chessboard Right here is as good a place as any...
//data/38950 ... sum ac za writes I am also look to help answer...
//data/38950 ... sum ac za writes I am also looking for a... chessboard Right here is as good a place as any...
//data/38950 ... sum ac za writes I am also look to help answer...
//data/38950 ... sum ac za writes I am an interested in facial animation.
//data/38950 ... sum ac za writes I am an interested in facial animation.
//data/38950 ... sum ac za writes I am an interested in facial animation in the complex of the complex proposed writes and proposed proposed proposed writes and propose
```

¹停用词采用的是网上查找的停用词

²写实验报告的时候发现此处实际上只需要扫描统计一次就够了

5 实验总结 4

5 实验总结

本次实验过程中我对信息提取技术和搜索引擎的具体实现有了更深刻的理解和认识,深切体会到为什么搜索领域的整体思路很简单,就是建立索引然后查找. 但是具体实现的时候有无数的实现细节和需要考虑的地方需要我们注意和学习. 因为实现时时间比较紧张,许多细节没有考虑(也同时感受到需要考虑的细节很多很多),希望之后还可以改进这个很原始的搜搜索引擎.